Classification d'émotions dans les dialogues de jeux vidéo

Rapport académique

Jourdan Wilson Mickaëla Mastrodicasa

Projet de Réseaux de Neurones

Université Paris Nanterre / Sorbonne Nouvelle

2026

Table des matières

1 Introduction et objectifs **3**

2 Données utilisées **3**

2.1 Origine des données 3

2.2 Format initial 4

2.3 Traitements opérés 4

2.4 Statut juridique 4

3 Méthodologie **4**

3.1 Répartition du travail 5

3.2 Difficultés rencontrées 5

4 Implémentation **5**

4.1 Technologies utilisées 6

4.2 Fonctionnement du modèle 6

4.3 Organisation du projet 6

5 Résultats **6**

5.1 Résultats de l'annotation humaine 8

5.2 Placeholders pour les figures 9

6 Discussion **9**

7 Conclusion et perspectives **9**

8 Bibliographie **10**

1. Introduction et objectifs

Ce projet porte sur la classification automatique des émotions dans les dialogues de jeux vidéo à l'aide de méthodes de traitement automatique du langage naturel et de réseaux de neurones. L'objectif principal consiste à développer un système capable d'identifier l'émotion dominante exprimée dans une réplique de personnage issue d'un jeu vidéo. Cette problématique s'inscrit dans le domaine de l'analyse des émotions, qui vise à modéliser automatiquement des phénomènes linguistiques liés à l'expression des affects.

Nous nous appuyons sur la typologie des émotions fondamentales proposée par Ekman. Le système doit ainsi distinguer sept catégories émotionnelles : la joie, la tristesse, la colère, la peur, la surprise, le dégoût et la neutralité. L'enjeu du projet est de déterminer dans quelle mesure un modèle pré-entraîné peut être appliqué à un corpus spécifique de dialogues de RPG, dont les propriétés diffèrent sensiblement de celles des jeux de données habituellement utilisés en analyse de sentiments.

Le projet poursuit plusieurs objectifs complémentaires. Il s'agit d'abord de constituer un corpus exploitable à partir de scripts de jeux vidéo, puis de nettoyer et structurer ces données textuelles afin de les rendre compatibles avec un traitement automatique. Une fois cette base constituée, nous appliquons un modèle de classification d'émotions afin d'obtenir des prédictions sur chaque dialogue. Enfin, nous confrontons ces résultats à une annotation humaine réalisée sur un sous-ensemble du corpus, de manière à évaluer la pertinence du système et à identifier ses limites. Une interface interactive a également été développée afin de faciliter l'exploration du modèle et de ses sorties.

Ce travail a été réalisé dans le cadre du cours de Réseaux de Neurones.

2. Données utilisées

2.1. Origine des données

Les données exploitées dans ce projet proviennent du corpus public *VideoGameDialogueCorpusPublic*, disponible à l'adresse suivante :

https://github.com/seannyD/VideoGameDialogueCorpusPublic

Ce corpus rassemble des scripts extraits de nombreux jeux vidéo appartenant à différents genres. Dans le cadre de cette étude, nous avons sélectionné plusieurs sous-ensembles appartenant principalement à la série *Final Fantasy*, afin d'obtenir un ensemble relativement homogène du point de vue narratif et stylistique. Ce choix s'explique par l'abondance des dialogues dans ces jeux ainsi que par la variété des situations émotionnelles qu'ils mettent en scène.

2.2. Format initial

Les données initiales étaient fournies sous forme de fichiers texte structurés de manière hétérogène. Les dialogues y étaient mélangés à d'autres types d'informations, comme des noms de personnages, des balises techniques telles que `SYSTEM`, `ACTION` ou `CHOICE`, des descriptions narratives, ainsi que des indications structurelles propres au déroulement du jeu. Cette hétérogénéité rendait les fichiers difficilement exploitables dans une tâche de classification automatique, car elle introduisait un bruit important susceptible de biaiser l'apprentissage.

2.3. Traitements opérés

Afin d'obtenir un corpus adapté à l'apprentissage automatique, nous avons mis en place un pipeline de prétraitement en deux étapes. Dans un premier temps, nous avons extrait les lignes de dialogue à partir des segments textuels placés entre guillemets. Cette opération a permis d'isoler les répliques des personnages. Dans un second temps, nous avons appliqué un nettoyage plus fin au corpus extrait. Les métadonnées techniques, les titres, les identifiants et les autres éléments non dialogués ont été supprimés. Les doublons ont également été éliminés afin d'éviter une surreprésentation artificielle de certaines formulations. De plus, les lignes contenant un nombre trop faible de mots ont été écartées, car elles apportaient rarement une information émotionnelle suffisamment exploitable. Enfin, le format textuel a été normalisé, notamment par la suppression des espaces superflus.

Le corpus final a été exporté sous forme de fichier CSV, en particulier sous le nom `dialogues_clean.csv`, qui constitue la base utilisée pour l'analyse et la prédiction des émotions.

2.4. Statut juridique

Les données proviennent d'un corpus public librement accessible en ligne. Elles ont été utilisées exclusivement dans un cadre académique et expérimental. Le projet n'a pas pour objectif de redistribuer les scripts originaux dans leur intégralité, mais uniquement de travailler sur une version transformée et nettoyée à des fins de recherche et d'évaluation.

3. Méthodologie

Le projet s'inscrit dans une démarche classique de machine learning appliqué au texte. La première étape a consisté à explorer le corpus afin de comprendre sa structure, de repérer les types d'informations présentes dans les scripts et d'identifier les éléments susceptibles de perturber l'apprentissage. Cette phase a permis de définir les critères de sélection et de nettoyage des données.

Nous avons ensuite développé un pipeline de prétraitement chargé d'extraire les dialogues et de produire un corpus exploitable. Cette étape s'est révélée essentielle, car la qualité du corpus conditionne directement la fiabilité des résultats obtenus par le modèle. Une fois le corpus constitué, nous avons sélectionné un modèle de classification d'émotions pré-entraîné, puis nous l'avons appliqué aux dialogues extraits. Pour chaque phrase, le système produit une prédiction correspondant à l'émotion la plus probable, ainsi qu'un score de confiance associé à cette prédiction.

Afin d'évaluer la pertinence du système, un sous-ensemble de 75 dialogues a été annoté manuellement. Deux annotateurs humains ont attribué une étiquette émotionnelle à chaque réplique. Cette étape a permis de comparer les jugements humains entre eux, puis de confronter les prédictions du modèle à une interprétation humaine des émotions. Enfin, plusieurs visualisations ont été générées afin d'observer la distribution des émotions dans le corpus, la répartition des scores de confiance et les exemples considérés comme les plus représentatifs pour chaque catégorie émotionnelle.

3.1. Répartition du travail

Le travail a été réparti entre les membres du groupe selon les différentes étapes du projet, comprenant la collecte et la préparation des données, le développement du pipeline de prétraitement, l'implémentation du modèle, l'annotation manuelle, la création de visualisations, la mise en place d'une interface interactive ainsi que la rédaction du rapport final. L'utilisation de GitHub a permis de centraliser les scripts et d'assurer un suivi cohérent de l'évolution du projet.

3.2. Difficultés rencontrées

Plusieurs difficultés ont été identifiées au cours du projet. La première concerne la présence importante de bruit dans les scripts de jeux vidéo, où les dialogues sont souvent mêlés à des informations techniques ou narratives. La seconde difficulté tient à l'ambiguïté de nombreuses répliques, souvent très courtes et difficilement interprétables hors contexte. Le déséquilibre entre les classes émotionnelles constitue également un problème, certaines catégories étant nettement plus fréquentes que d'autres. Enfin, un désaccord non négligeable entre annotateurs humains a été observé, ce qui confirme que la tâche de classification d'émotions comporte une part d'interprétation subjective.

4. Implémentation

Le modèle utilisé repose sur une architecture Transformer pré-entraînée, disponible via la bibliothèque Hugging Face :

https://huggingface.co/j-hartmann/emotion-english-distilroberta-base

Il s'agit d'un modèle *DistilRoBERTa* spécialisé dans la classification d'émotions en anglais. Son intérêt réside dans sa capacité à produire des représentations contextuelles du texte, permettant de mieux prendre en compte les relations sémantiques entre les mots qu'une approche fondée uniquement sur des fréquences lexicales.

4.1. Technologies utilisées

Le projet a été implémenté principalement en Python. La bibliothèque `pandas` a été utilisée pour la manipulation des données, `transformers` pour le chargement et l'utilisation du modèle, PyTorch comme backend de calcul, et `matplotlib` pour la génération des visualisations. Une interface interactive a également été développée avec Gradio afin de permettre l'exploration du modèle sur des dialogues isolés ou sur des fichiers complets.

4.2. Fonctionnement du modèle

Le fonctionnement du système repose sur plusieurs étapes successives. Le texte est d'abord tokenisé, puis converti en représentations vectorielles contextuelles. Le modèle calcule ensuite une distribution de probabilité sur les sept émotions considérées. L'émotion correspondant à la probabilité la plus élevée est retenue comme prédiction finale, accompagnée d'un score de confiance. Cette approche permet non seulement d'obtenir une étiquette émotionnelle dominante, mais aussi d'évaluer la certitude relative du système pour chaque prédiction.

4.3. Organisation du projet

Le dépôt Git a été structuré en plusieurs dossiers correspondant aux différentes composantes du projet. Le dossier `data` contient les données brutes et nettoyées. Le dossier `preprocessing` rassemble les scripts d'extraction et de nettoyage. Le dossier `models` contient les modules de prédiction et les scripts d'analyse. Le dossier `annotation` regroupe les annotations humaines ainsi que les fichiers d'évaluation. Enfin, le dossier `figures` rassemble les visualisations produites au cours du projet.

5. Résultats

Les résultats obtenus permettent d'analyser à la fois la distribution des émotions dans le corpus et le comportement du modèle face à différents types de dialogues. La Figure 1 présente la répartition des émotions prédites dans l'ensemble du corpus. On y observe une forte présence de la classe *neutre*, ce qui s'explique par la nature souvent informative ou descriptive des dialogues de jeux vidéo. De nombreuses répliques servent en effet à transmettre des informations sur l'univers narratif, les quêtes ou les interactions fonctionnelles entre personnages, plutôt qu'à exprimer explicitement un état affectif.

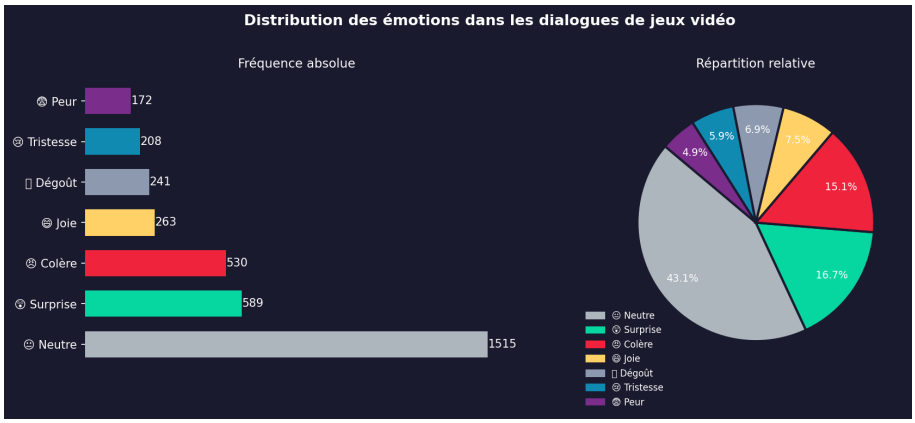

FIGURE 1 – Distribution des émotions prédites dans le corpus.

La Figure 2 montre la distribution des scores de confiance associés aux prédictions du modèle. On constate que celui-ci attribue généralement des probabilités relativement élevées à ses sorties, avec une confiance moyenne d'environ 75,4%. Ce résultat suggère que le modèle identifie des régularités cohérentes dans le corpus, même si un score de confiance élevé ne garantit pas nécessairement l'exactitude de la prédiction.

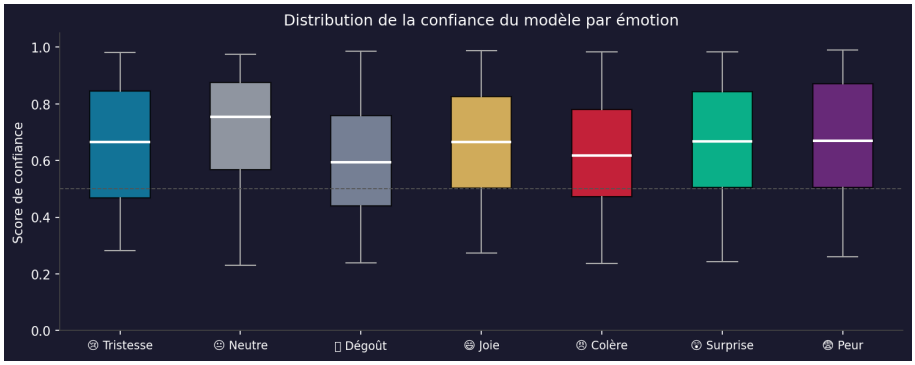

FIGURE 2 – Distribution des scores de confiance selon l'émotion prédite.

Afin d'illustrer qualitativement les résultats, nous avons également retenu les dialogues pour lesquels le modèle attribue la probabilité la plus élevée à chaque émotion. La Figure 3 présente ces exemples représentatifs. Ces extraits permettent de mieux comprendre quels indices linguistiques semblent orienter le modèle, comme la présence d'interjections, de formulations injonctives ou d'expressions évaluatives.

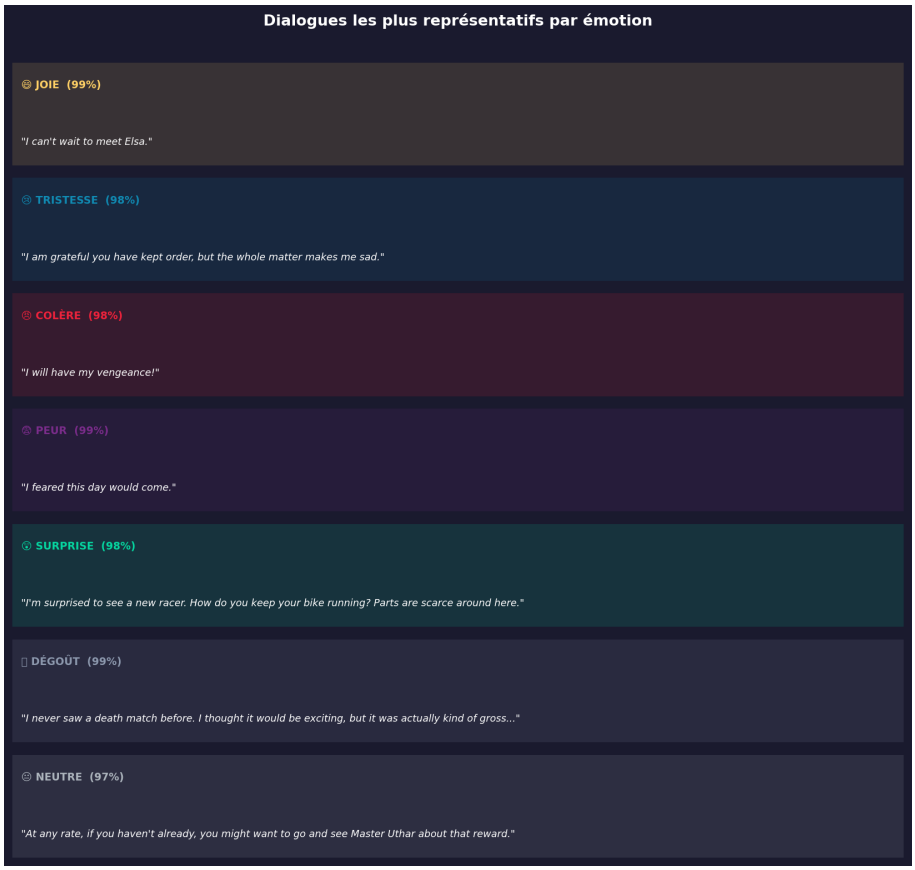

FIGURE 3 – Exemples de dialogues les plus représentatifs pour chaque émotion.

5.1. Résultats de l'annotation humaine

Afin d'évaluer plus précisément la qualité des prédictions, un sous-ensemble de 75 dialogues a été annoté manuellement par deux annotateurs humains. L'accord inter-annotateurs atteint 51%, ce qui montre que l'interprétation émotionnelle d'un dialogue peut varier selon les individus. L'accord entre le modèle et un annotateur humain atteint quant à lui 39%, ce qui indique que le système parvient à capter certaines tendances générales, mais reste limité face à l'ambiguïté contextuelle de nombreuses répliques.

La Figure 4 synthétise les résultats de cette étape d'évaluation, en présentant les scores d'accord entre annotateurs, la comparaison entre annotations humaines et modèle, ainsi que la confiance moyenne des prédictions.

Nb. dialogues annotés	75
% accord modèle / Annot. 1	39%
% accord Annot. 1 / Annot. 2	51%
Confiance moyenne du modèle	75,4%

FIGURE 4 – Comparaison entre annotations humaines et prédictions du modèle.

5.2. Placeholders pour les figures

Si certaines figures ne sont pas encore disponibles au moment de la rédaction sur Overleaf, elles peuvent être remplacées temporairement par des blocs de substitution afin de conserver la structure du document et la cohérence des renvois internes. Les visuels définitifs pourront ensuite être insérés dans le dossier `figures` en conservant les mêmes noms de fichiers.

6. Discussion

L'analyse des résultats met en évidence plusieurs limites liées à la nature du corpus. Les dialogues sont souvent courts et ne contiennent pas toujours d'indices lexicaux explicites permettant d'identifier une émotion précise. Dans de nombreux cas, la compréhension de l'émotion dépend du contexte narratif, de la situation du personnage ou de la réplique précédente, éléments qui ne sont pas pris en compte lorsque chaque phrase est analysée isolément.

Certaines confusions apparaissent de manière récurrente, notamment entre les catégories tristesse et neutralité, ou entre surprise et peur. Ces proximités sémantiques compliquent la tâche de classification, y compris pour des annotateurs humains. L'accord modéré observé entre annotateurs confirme d'ailleurs que cette tâche comporte une dimension interprétative importante. Une partie des erreurs du modèle reflète donc l'ambiguïté intrinsèque des données elles-mêmes.

Nous aurions souhaité approfondir plusieurs aspects du projet. Il aurait notamment été intéressant d'annoter un corpus plus large, de mieux équilibrer les classes émotionnelles, d'adapter ou de réentraîner un modèle spécifiquement sur des dialogues de jeux vidéo, ainsi que d'intégrer le contexte conversationnel pour améliorer l'interprétation des répliques ambiguës.

7. Conclusion et perspectives

Ce projet montre qu'il est possible d'appliquer des modèles de deep learning à l'analyse émotionnelle de dialogues de jeux vidéo. Le pipeline développé permet de transformer des scripts bruts en un corpus structuré et exploitable, puis d'obtenir des prédictions d'émotions globalement cohérentes.

L'analyse des résultats met toutefois en évidence plusieurs limites, notamment l'ambiguïté des dialogues courts, l'absence de contexte conversationnel et le poids important de la classe neutre dans le corpus. Malgré ces limites, les résultats obtenus montrent que les modèles de traitement automatique du langage sont capables de capter certaines régularités linguistiques associées à l'expression des émotions.

Les perspectives d'amélioration incluent l'annotation d'un corpus plus important, l'intégration du contexte conversationnel, l'adaptation du modèle au domaine spécifique du jeu vidéo, ainsi que l'exploration d'autres architectures de classification. Ce travail constitue ainsi une première base pour des recherches futures en analyse narrative et émotionnelle appliquée aux dialogues interactifs.

8. Bibliographie

Références

[1] Ekman, P. (1992). An argument for basic emotions. *Cognition and Emotion*, 6(3-4), 169–200.

[2] Liu, Y. et al. (2019). RoBERTa : A Robustly Optimized BERT Pretraining Approach. *arXiv preprint arXiv :1907.11692*.

[3] Sanh, V., Debut, L., Chaumond, J., & Wolf, T. (2019). DistilBERT, a distilled version of BERT : smaller, faster, cheaper and lighter. *arXiv preprint arXiv :1910.01108*.

[4] Wolf, T. et al. (2020). Transformers : State-of-the-Art Natural Language Processing. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing : System Demonstrations*, 38–45.

[5] SeannyD. VideoGameDialogueCorpusPublic. https://github.com/seannyD/VideoGameDialogueCorpusPublic

[6] Hartmann, J. emotion-english-distilroberta-base. https://huggingface.co/j-hartmann/emotion-english-distilroberta-base