Classification d'émotions dans les dialogues de jeux vidéo

Jourdan Wilson Mickaëla Mastrodicasa

Projet Final de Réseaux de Neurones

Interfaces Web

Université Paris Nanterre / Sorbonne Nouvelle

M2 TAL 2026

Table des matières

1 Introduction et objectifs **3**

2 Données utilisées **4**

2.1 Origine des données 4

2.2 Format initial 6

2.3 Traitements opérés 6

3 Méthodologie **6**

3.1 Répartition du travail 7

3.2 Difficultés rencontrées 7

4 Implémentation **8**

4.1 Technologies utilisées 8

4.2 Interface Web 8

4.3 Fonctionnement du modèle 8

5 Résultats **9**

5.1 Résultats de l'annotation humaine 10

6 Discussion **11**

7 Conclusion et perspectives **12**

8 Bibliographie **12**

1. Introduction et objectifs

Ce projet porte sur la classification automatique des émotions dans les dialogues de jeux vidéo avec des méthodes du TAL et de réseaux de neurones. L'objectif principal consiste à développer un système capable d'identifier l'émotion dominante exprimée dans une réplique de personnage issue d'un jeu vidéo. Cette problématique s'inscrit dans le domaine de l'analyse des émotions, qui vise à modéliser automatiquement des phénomènes linguistiques liés à l'expression des affects. C'est un sujet sur lequel nous travaillons beaucoup avec Madame Batistelli dans ce master.

Nous nous appuyons sur la typologie des émotions fondamentales proposée par Ekman [1]. Selon cette approche, certaines émotions seraient universelles et reconnaissables à travers différentes cultures, car elles reposent sur des mécanismes cognitifs et physiologiques communs. Ekman identifie initialement six émotions dites « de base » : la joie, la tristesse, la colère, la peur, la surprise et le dégoût. L'utilisation d'un nombre limité de catégories facilite l'apprentissage supervisé tout en permettant de capturer une variété de nuances affectives présentes dans les données textuelles.

Dans le cadre de notre projet, nous retenons sept catégories émotionnelles, en ajoutant la classe neutre aux six émotions fondamentales. Cette catégorie supplémentaire permet de rendre compte des énoncés qui ne comportent pas d'indice émotionnel marqué, ce qui est fréquent dans les dialogues de jeux vidéo. En effet, de nombreuses répliques ont une fonction informative, stratégique ou interactionnelle plutôt qu'expressive. L'intégration de la catégorie neutre permet donc d'éviter d'attribuer artificiellement une émotion à des phrases qui n'en expriment pas clairement.

L'enjeu du projet est de déterminer dans quelle mesure un modèle pré-entraîné peut être appliqué à un corpus spécifique de dialogues de RPG, dont les propriétés diffèrent sensiblement de celles des jeux de données habituellement utilisés en analyse de sentiments. Contrairement aux corpus classiques, souvent composés d'avis utilisateurs, de commentaires en ligne ou de messages issus des réseaux sociaux, les dialogues de jeux vidéo sont généralement plus courts, fortement dépendants du contexte narratif et contiennent fréquemment des émotions implicites plutôt qu'explicitement exprimées. Le style linguistique peut inclure des éléments propres à l'univers fictionnel, tels que du vocabulaire spécifique, des formulations dramatiques ou des structures elliptiques. Ces particularités rendent la tâche de classification plus complexe.

Le projet poursuit plusieurs objectifs complémentaires. Il s'agit d'abord de constituer un corpus exploitable à partir de scripts de jeux vidéo, puis de nettoyer et structurer ces données textuelles afin de les rendre compatibles avec un traitement automatique. Une fois cette base constituée, nous appliquons un modèle de classification d'émotions afin d'obtenir des prédictions sur chaque dialogue. Enfin, nous confrontons ces résultats à une annotation humaine réalisée sur un sous-ensemble du corpus, pour évaluer la pertinence

du système et identifier ses limites. Une interface interactive a également été développée afin de faciliter l'exploration du modèle et de ses sorties.

2. Données utilisées

2.1. Origine des données

Les données exploitées dans ce projet proviennent du corpus public VideoGameDialogueCorpusPublic, disponible à l'adresse suivante :

https://github.com/seannyD/VideoGameDialogueCorpusPublic

Ce corpus rassemble des scripts extraits de nombreux jeux vidéo appartenant à différents genres. Nous avons sélectionné plusieurs sous-ensembles. Ce choix s'explique par l'abondance des dialogues dans ces jeux ainsi que par la variété des situations émotionnelles qu'ils mettent en scène.

Le choix de travailler sur des données en anglais s'explique principalement par la disponibilité de ressources linguistiques et de modèles pré-entraînés de haute qualité dans cette langue. De nombreux modèles performants de traitement automatique du langage, notamment ceux fondés sur des architectures Transformer, ont été entraînés sur de grands corpus anglophones. Le modèle utilisé dans ce projet, *emotion-english-distilroberta-base*, a lui-même été entraîné sur des données annotées en anglais pour la classification d'émotions. L'utilisation de données dans la même langue permet donc de garantir une meilleure compatibilité entre le corpus et le modèle, ainsi que des performances plus fiables. Une grande partie des scripts de jeux vidéo disponibles publiquement est rédigée en anglais, ce qui facilite l'accès à un volume plus important de données.

Table 1 – Jeux du corpus

Super Mario RPG	RPG
Star Wars : Knights of the Old Republic	RPG / Sci-Fi
Phoenix Wright : Ace Attorney	Visual Novel / Enquête
Chrono Trigger	JRPG
Dragon Age II	RPG occidental
Dragon Age : Origins	RPG occidental
The Elder Scrolls V : Skyrim	RPG / Monde ouvert
Hades	Roguelite
Horizon Zero Dawn	Action-RPG
The Secret of Monkey Island	Point-and-click
Persona 3	JRPG
Persona 4	JRPG
Persona 5	JRPG
Mass Effect	RPG / Sci-Fi
Mass Effect 2	RPG / Sci-Fi
Mass Effect 3	RPG / Sci-Fi
Kingdom Hearts	Action-RPG
Kingdom Hearts II	Action-RPG
Kingdom Hearts III	Action-RPG
Kingdom Hearts Birth by Sleep	Action-RPG
Kingdom Hearts Dream Drop Distance	Action-RPG
King's Quest II	Aventure
King's Quest III	Aventure
King's Quest IV	Aventure
King's Quest V	Aventure
King's Quest VI	Aventure
Final Fantasy II	JRPG
Final Fantasy III	JRPG
Final Fantasy IV	JRPG
Final Fantasy V	JRPG
Final Fantasy VI	JRPG
Final Fantasy VII	JRPG
Final Fantasy VIII	JRPG
Final Fantasy X	JRPG

2.2. Format initial

Les données initiales étaient fournies sous forme de fichiers texte structurés de manière hétérogène. Les dialogues y étaient mélangés à d'autres types d'informations, comme des noms de personnages, des balises techniques telles que `SYSTEM`, `ACTION` ou `CHOICE`, des descriptions narratives, ainsi que des indications structurelles propres au déroulement du jeu. Cette hétérogénéité rendait les fichiers difficilement exploitables dans une tâche de classification automatique car elle introduisait un bruit important susceptible de biaiser l'apprentissage.

2.3. Traitements opérés

Nous avons mis en place un pipeline de prétraitement en deux étapes. Dans un premier temps, nous avons extrait les lignes de dialogue à partir des segments textuels placés entre guillemets. Cette opération a permis d'isoler les répliques des personnages. Dans un second temps, nous avons appliqué un nettoyage plus fin au corpus extrait. Les métadonnées techniques, les titres, les identifiants et les autres éléments non dialogués ont été supprimés. Les doublons ont également été éliminés afin d'éviter une surreprésentation artificielle de certaines formulations. De plus, les lignes contenant un nombre trop faible de mots ont été écartées, car elles apportaient rarement une information émotionnelle suffisamment exploitable. Enfin, le format textuel a été normalisé, notamment par la suppression des espaces superflus. Le corpus final a été exporté sous forme de fichier CSV et constitue la base utilisée pour l'analyse et la prédiction des émotions.

3. Méthodologie

La première étape a consisté à explorer le corpus afin de comprendre sa structure, de repérer les types d'informations présentes dans les scripts et d'identifier les éléments susceptibles de perturber l'apprentissage. Cette phase a permis de définir les critères de sélection et de nettoyage des données.

Une fois le corpus constitué, nous avons sélectionné un modèle de classification d'émotions pré-entraîné, puis nous l'avons appliqué aux dialogues extraits. Pour chaque phrase, le système produit une prédiction correspondant à l'émotion la plus probable, ainsi qu'un score de confiance associé à cette prédiction.

Afin d'évaluer la pertinence du système, un sous-ensemble de 75 dialogues a été annoté manuellement. Nous avons attribué une étiquette émotionnelle à chaque réplique. Cette étape a permis de comparer les jugements humains entre eux, puis de confronter les prédictions du modèle à une interprétation humaine des émotions. Enfin, plusieurs visualisations ont été générées afin d'observer la distribution des émotions dans le corpus, la répartition des scores de confiance et les exemples considérés comme les plus représentatifs

pour chaque catégorie émotionnelle.

3.1. Répartition du travail

Le travail a été réparti équitablement entre nous, et nous avons collaboré tout au long des différentes étapes du projet, notamment la collecte et la préparation des données, le développement du pipeline de prétraitement, la mise en œuvre du modèle, l'annotation manuelle, la création de visualisations, le développement d'une interface interactive et la rédaction du rapport final. Le dépôt Git a été structuré en plusieurs dossiers correspondant aux différentes composantes du projet.

3.2. Difficultés rencontrées

Plusieurs difficultés ont été identifiées au cours du projet. La première concerne la présence importante de bruit dans les scripts de jeux vidéo, où les dialogues sont souvent mêlés à des informations techniques, des balises de système ou des descriptions narratives. Cette hétérogénéité complique l'extraction automatique des données pertinentes et nécessite la mise en place d'un prétraitement rigoureux afin d'isoler uniquement les répliques exploitables.

La seconde difficulté tient à l'ambiguïté de nombreuses répliques. Les dialogues sont fréquemment courts, elliptiques et fortement dépendants du contexte narratif, ce qui rend leur interprétation délicate lorsqu'ils sont considérés de manière isolée. Dans certains cas, une même phrase peut être associée à plusieurs émotions possibles selon la situation, le ton implicite ou les connaissances du lecteur. Certaines phrases peuvent paraître neutres ou peu informatives lorsqu'elles sont isolées, alors qu'elles prennent un sens émotionnel particulier dans le déroulement de l'histoire. L'absence de contexte conversationnel complet constitue donc une limite importante pour l'interprétation automatique des émotions.

Le déséquilibre entre les classes émotionnelles constitue également un enjeu important. Certaines catégories, en particulier la classe neutre, sont largement surreprésentées dans le corpus. Ce déséquilibre peut influencer le comportement du modèle, qui tend alors à privilégier les classes majoritaires au détriment des émotions moins fréquentes.

Enfin, un désaccord non négligeable entre nous, les annotateurs humains a été observé lors de l'évaluation manuelle. Ce phénomène met en évidence la dimension subjective de la classification des émotions, où les interprétations peuvent varier en fonction de la sensibilité individuelle, de la compréhension du contexte ou des critères d'annotation adoptés. Ces difficultés confirment que la tâche de classification d'émotions, en particulier sur des dialogues narratifs, demeure complexe tant pour les modèles automatiques que pour les humains.. Il confirme également que certaines erreurs du modèle ne résultent pas uniquement de limitations techniques, mais reflètent également l'ambiguïté inhérente au langage naturel.

4. Implémentation

Le modèle utilisé repose sur une architecture Transformer pré-entraînée, disponible via la bibliothèque Hugging Face :

https://huggingface.co/j-hartmann/emotion-english-distilroberta-base

Il s'agit d'un modèle DistilRoBERTa spécialisé dans la classification d'émotions en anglais. Son intérêt est sa capacité à produire des représentations contextuelles du texte, qui permet de mieux prendre en compte les relations sémantiques entre les mots qu'une approche fondée uniquement sur des fréquences lexicales.

4.1. Technologies utilisées

Le projet a été implémenté principalement en Python. La bibliothèque pandas a été utilisée notamment pour le chargement, le filtrage et l'export des corpus au format tabulaire et faciliter les étapes du prétraitement.

La bibliothèque transformers a été utilisée pour charger et exploiter le modèle pré-entraîné de classification d'émotions. Le modèle repose sur le framework PyTorch, qui constitue le backend de calcul et permet d'effectuer les opérations nécessaires au traitement des données et à la production des prédictions.

Les visualisations ont été réalisées avec la bibliothèque matplotlib pour représenter graphiquement la distribution des émotions et les scores de confiance du modèle.

Enfin, une interface interactive a été développée à l'aide de la bibliothèque Gradio. Cette interface permet d'explorer le fonctionnement du modèle en mettant des exemples de dialogues directement depuis une interface web.

4.2. Interface Web

L'interface a une couche programmatique similaire à une API permettant d'envoyer des requêtes contenant du texte et de recevoir en réponse les prédictions du modèle. Ce fonctionnement correspond au principe d'une API REST où un service peut être interrogé à distance pour obtenir des analyses linguistiques. L'interface rend ainsi le modèle accessible sans nécessiter de manipulations directes du code Python.

4.3. Fonctionnement du modèle

Le fonctionnement repose sur plusieurs étapes. Le texte est d'abord tokenisé, puis converti en représentations vectorielles contextuelles. Le modèle calcule ensuite une distribution de probabilité sur les sept émotions considérées. L'émotion correspondant à la probabilité la plus élevée est retenue comme prédiction finale, accompagnée d'un score de confiance. Cette approche permet non seulement d'obtenir une étiquette émotionnelle dominante, mais aussi d'évaluer la certitude relative du système pour chaque prédiction.

5. Résultats

Les résultats obtenus permettent d'analyser à la fois la distribution des émotions dans le corpus et le comportement du modèle face à différents types de dialogues. La Figure 1 présente la répartition des émotions prédites dans l'ensemble du corpus. On observe une forte présence de la classe *neutre*, comme indiqué précédemment. De nombreuses répliques servent en effet à transmettre des informations sur l'univers narratif, les quêtes ou les interactions fonctionnelles entre personnages, plutôt qu'à exprimer explicitement un état affectif.

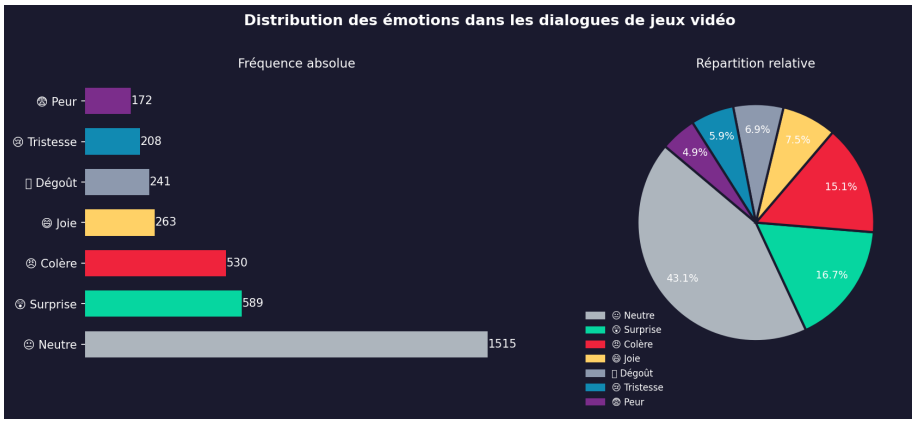

FIGURE 1 – Distribution des émotions prédites dans le corpus.

La Figure 2 montre la distribution des scores de confiance associés aux prédictions du modèle. On constate que celui-ci attribue généralement des probabilités relativement élevées à ses sorties, avec une confiance moyenne d'environ 75,4%. Ce résultat suggère que le modèle identifie des régularités cohérentes dans le corpus, même si un score de confiance élevé ne garantit pas nécessairement l'exactitude de la prédiction.

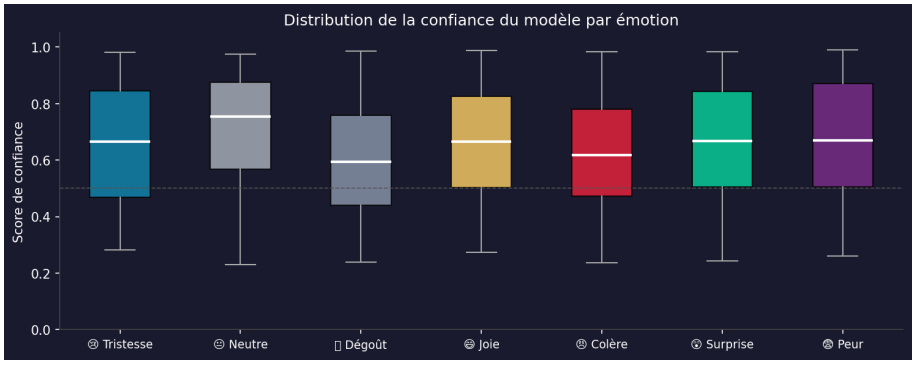

FIGURE 2 – Distribution des scores de confiance selon l'émotion prédite.

Afin d'illustrer qualitativement les résultats, nous avons également retenu les dialogues pour lesquels le modèle attribue la probabilité la plus élevée à chaque émotion. La Figure 3 présente ces exemples représentatifs. Ces extraits permettent de mieux comprendre quels

indices linguistiques semblent orienter le modèle, comme la présence d'interjections, de formulations injonctives ou d'expressions évaluatives.

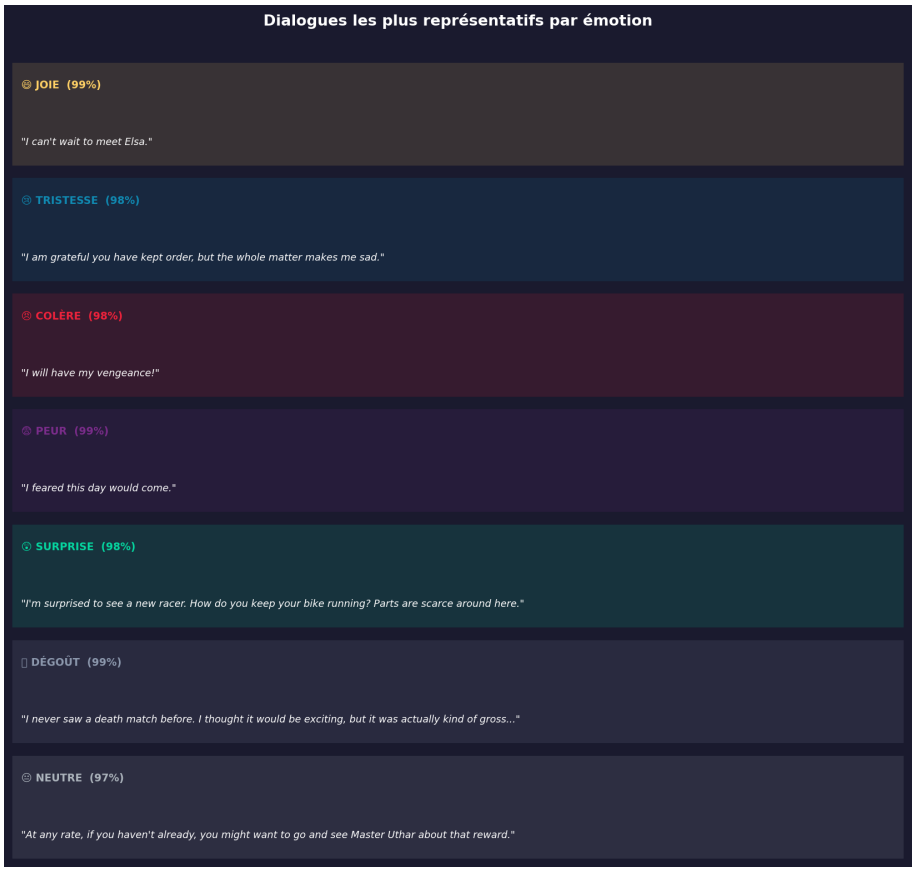

FIGURE 3 – Exemples de dialogues les plus représentatifs pour chaque émotion.

5.1. Résultats de l'annotation humaine

Afin d'évaluer plus précisément la qualité des prédictions du modèle, un sous-ensemble de 75 dialogues a été annoté manuellement par nous, deux annotateurs humains. Chaque annotateur a attribué de manière indépendante une étiquette émotionnelle à chaque réplique, en se basant uniquement sur le contenu textuel disponible, sans accès au contexte narratif complet du jeu. Cette procédure visait à constituer une référence comparative permettant d'évaluer la cohérence des prédictions automatiques.

L'accord inter-annotateurs atteint 51%, ce qui indique un niveau de concordance modéré. Ce résultat montre que l'interprétation émotionnelle d'un dialogue peut varier selon les individus, notamment lorsque les énoncés sont courts, implicites ou ambigus. Certaines répliques peuvent en effet être associées à plusieurs émotions plausibles selon la manière dont l'annotateur interprète la situation narrative, le ton implicite ou l'intention du personnage. Ce phénomène met en évidence la dimension subjective de la classification des émotions, même dans un cadre d'annotation contrôlé.

L'accord entre le modèle et les annotateurs humains atteint quant à lui 39%, ce qui

indique que le système parvient à capter certaines tendances générales présentes dans les données, tout en restant limité face à l'ambiguïté contextuelle de nombreuses répliques. Ce niveau d'accord suggère que le modèle identifie correctement certaines expressions émotionnelles explicites, mais rencontre davantage de difficultés lorsque l'émotion dépend d'informations implicites ou d'éléments contextuels absents du texte analysé.

La Figure 4 synthétise les résultats de cette étape d'évaluation. Elle présente notamment la comparaison entre les annotations humaines et les prédictions du modèle, ainsi que le score de confiance moyen associé aux classifications automatiques.

Nb. dialogues annotés	75
% accord modèle / Annot. 1	39%
% accord Annot. 1 / Annot. 2	51%
Confiance moyenne du modèle	75,4%

FIGURE 4 – Comparaison entre annotations humaines et prédictions du modèle.

6. Discussion

L'analyse des résultats met en évidence plusieurs limites liées à la nature du corpus. Les dialogues sont souvent courts et ne contiennent pas toujours d'indices lexicaux explicites permettant d'identifier une émotion précise. Dans de nombreux cas, la compréhension de l'émotion dépend du contexte narratif, de la situation du personnage ou de la réplique précédente, éléments qui ne sont pas pris en compte lorsque chaque phrase est analysée isolément.

Certaines confusions apparaissent de manière récurrente, notamment entre les catégories tristesse et neutralité, ou entre surprise et peur. Ces proximités sémantiques compliquent la tâche de classification, compris pour nous les annotateurs humains. Une partie des erreurs du modèle reflète donc l'ambiguïté intrinsèque des données elles-mêmes.

Nous aurions souhaité approfondir plusieurs aspects du projet. Il aurait notamment été intéressant d'annoter un corpus plus large, de mieux équilibrer les classes émotionnelles, d'adapter ou de réentraîner un modèle spécifiquement sur des dialogues de jeux vidéo, ainsi que d'intégrer le contexte conversationnel pour améliorer l'interprétation des répliques ambiguës.

Le modèle utilisé dans ce projet a été entraîné sur des données générales d'analyse d'émotions, telles que des commentaires en ligne ou des messages issus de réseaux sociaux. Les dialogues de jeux vidéo présentent des caractéristiques linguistiques particulières. En entraînant le modèle sur des données plus proches de ce domaine, il serait possible d'améliorer sa capacité à reconnaître des indices émotionnels implicites propres aux dialogues narratifs.

L'interprétation émotionnelle d'un énoncé dépend souvent de son contexte discursif aussi. La prise en compte des tours de parole précédents ou de la dynamique de l'échange pourrait permettre de mieux désambiguïser certaines répliques, en particulier lorsque l'émotion n'est pas explicitement exprimée dans le texte lui-même.

7. Conclusion et perspectives

Ce projet montre qu'il est possible d'appliquer des modèles de deep learning à l'analyse émotionnelle de dialogues de jeux vidéo. Le pipeline développé permet de transformer des scripts bruts en un corpus structuré et exploitable, puis d'obtenir des prédictions d'émotions globalement cohérentes.

L'analyse des résultats met toutefois en évidence plusieurs limites, notamment l'ambiguïté des dialogues courts et le poids important de la classe neutre dans le corpus. Malgré ces limites, les résultats obtenus montrent que les modèles de traitement automatique du langage sont capables de capter certaines régularités linguistiques associées à l'expression des émotions.

8. Bibliographie

Références

[1] Ekman, P. (1992). An argument for basic emotions. *Cognition and Emotion*, 6(3-4), 169–200.

[2] Liu, Y. et al. (2019). RoBERTa : A Robustly Optimized BERT Pretraining Approach. *arXiv preprint arXiv :1907.11692*.

[3] Sanh, V., Debut, L., Chaumond, J., & Wolf, T. (2019). DistilBERT, a distilled version of BERT : smaller, faster, cheaper and lighter. *arXiv preprint arXiv :1910.01108*.

[4] SeannyD. VideoGameDialogueCorpusPublic. https://github.com/seannyD/VideoGameDialogueCorpusPublic

[5] Hartmann, J. emotion-english-distilroberta-base. https://huggingface.co/j-hartmann/emotion-english-distilroberta-base